贝叶斯流排序框架：非补偿性多准则分类的参数学习与不确定性量化

摘要

多准则分类问题（MCCP）中，流排序（FlowSort）方法已被证明是处理具有非补偿性特征分类问题的有效工具，但其依赖决策者给出具体的偏好参数，即准则权重、偏好阈值以及漠视阈值，而使用线性规划方法估计这些参数存在一定缺陷，实证表明，该方法鲁棒性较弱，在权重 ± 10%扰动下分类跳变率高达 35%；此外，确定性的优化模型无法量化数据噪声带来的不确定性，且提供标准参考轮廓往往给决策者带来较高的认知负荷。针对上述问题，本文提出一种概率化建模的贝叶斯流排序（BFS）框架，用于非补偿性多准则分类问题的参数学习与不确定性量化。该框架将流排序模型中的参考轮廓与偏好参数视为随机变量，在轮廓推断层面，采用数据驱动策略，从历史分类数据中自适应提取标准参考轮廓；在参数推断层面，构建基于流值距离的似然函数，利用蒙特卡洛（MCMC）采样对复杂的后验分布进行近似推断。通过将分类过程表述为基于偏好流距离的概率生成机制，模型为每个备选方案输出属于各类别的后验概率，从而提供具有统计意义的分类置信度。仿真实验结果表明，所提出的贝叶斯流排序框架在参考轮廓不确定或偏好信息有限的情形下，能够稳定输出高质量的分类结果及其置信度，相较于线性规划方法展现出更好的鲁棒性与决策支持价值。

【关键词】

多准则分类；贝叶斯推断；FlowSort；参数不确定性；轮廓缺失场景

1.引言

多准则分类（MCS）旨在依据决策者（DM）的偏好将备选方案分配至预定义的有序类别中，是管理科学与运筹学领域解决分级与筛选问题的核心工具。在现有的方法论体系中，主流模型主要分为基于效用理论的价值函数法和基于排出流关系的排序方法。前者以 UTADIS 及其扩展模型为代表，通过构建加性价值函数聚合各准则绩效，计算效率较高。但其内在的完全补偿性假设难以刻画信贷风险评估、医疗诊断、工业故障模式分级等高风险场景中决策者对于某些关键准则的非补偿性特征。以故障模式与影响分析（FMEA）为例，若某一系统故障的严重度达到致命级别，即便其发生概率很低或可探测度很高，决策者仍倾向于遵循非补偿性的原则，将其直接归类为高风险等级。相比之下，以 ELECTRE-TRI 系列和 FlowSort 方法为核心的非补偿性模型，通过成对比较构建优劣关系，能够有效保留准则间的冲突信息。其中，FlowSort 方法因结合了 PROMETHEE 的净流概念与参考轮廓的分类机制，为基于阈值的分类任务提供了严谨的结构化框架。

无论采用何种模型，决策结果的可靠性均取决于模型参数（如权重、偏好阈值、参考轮廓）能否真实反映决策者的偏好结构。由于非补偿性模型参数维度高且缺乏直观的认知解释，直接要求决策者精确指定这些参数往往会导致较高的认知负荷与偏差。因此，通过决策者提供的赋值示例反推模型参数的间接偏好获取方式，即偏好学习的思想，已成为学术界的主流选择。在这一思想下，传统的参数推断主要依赖于确定性数学规划技术：对于价值函数模型，通常采用线性规划（LP）或最小二乘法（LS）；对于非补偿性模型，则多采用混合整数规划（MIP）或最大似然估计（MLE），旨在寻找一组能够最大程度复现已知赋值示例的最优参数解。

然而，在处理此类有限偏好信息的学习问题时，上述确定性优化方法存在的问题在于无法提供分类结果的置信度度量。由于决策者受认知能力所限，能够提供的赋值示例通常数量稀缺，导致偏好学习本质上是一个不适定问题。这意味着往往存在一个由多组参数构成的可行参数空间，该空间内的所有参数组均能解释已知的偏好信息。LP、LS 或 MLE 等方法本质上是在寻找点估计，即仅从可行

空间中选取单一的特定解作为决策依据。这种做法虽然在数学上给出了唯一的分类结果，但忽略了参数选择的随机性风险，无法告知决策者该分类结果的可信程度。在实际应用中，参数的微小扰动可能导致分类结果的跳变，这种缺乏置信度量化的方法极大地限制了模型在复杂决策环境下的适用性。

为解决多解性与鲁棒性问题，现有文献发展了两条主要路径来探索参数空间。第一条路径是鲁棒序数回归（ROR），它推导必要和可能的分类结果，但其本质上仍基于逻辑判断而非概率度量。第二条路径是随机多准则可接受性分析（SMAA）及其分类变体 SMAA-Tri，通过计算类可接受指数提供概率解释。尽管 SMAA 克服了点估计的片面性，但其通常假设可行空间内所有参数组合服从均匀分布，忽略了不同参数组在解释历史数据时存在的似然程度差异。这种可能导致边缘参数被高估，从而使得输出的概率指标难以作为精确的置信度度量。相比之下，贝叶斯序数回归为处理参数不确定性提供了更严谨的统计学方式。正如 Ru 等人在加性价值函数模型中所证实的，贝叶斯方法能够通过似然函数将偏好数据转化为参数的后验分布，在无需假设均匀分布的前提下，精确量化不同参数组合的解释力，从而输出具有统计学意义的分类置信度。

尽管这一方式在补偿性模型中已取得成功，但将其拓展至 FlowSort 等非补偿性模型并非直接的平移应用。与加性模型平滑的连续函数特征不同，FlowSort 模型依赖于离散的成对比较逻辑与复杂的双重阈值机制，这种内在的非连续性使得构建有效的似然函数与后验推断框架变得极具挑战性。此外，现有的参数学习方法大多假设类别的参考轮廓是已知且固定的常量，而在实际决策初期，参考轮廓本身往往是不确定的随机变量。若无法在一个统一的概率框架内同时处理权重、阈值及参考轮廓的联合不确定性，就无法真正实现对非补偿性分类风险的准确评估。

鉴于此，本文旨在提出一种基于概率建模的贝叶斯 FlowSort 框架，以解决非补偿性偏好结构下的参数推断与置信度量化问题。不同于寻找单一参数解的传统思路，本研究在贝叶斯推断逻辑下，重新构建了适应 FlowSort 非连续特征的似然函数，将全套参数集构建为联合随机变量，并利用马尔可夫链蒙特卡罗（MCMC）算法对高度复杂的后验分布进行采样。该方法的核心贡献在于建立了一个能够直接计算备选方案类分配概率的统一计算框架，特别是突破了原有方

法对参考轮廓已知性的依赖，实现了对类别边界的自适应推断。为了验证所提框架的有效性，本研究将确定性的数学规划方法作为基准，通过比较实验实证分析了贝叶斯框架在处理参数扰动与通过有限偏好信息学习时的鲁棒性优势。 这一框架不仅融合了偏好信息的不一致性与全参数空间的随机性，更为决策者提供了一个直观且严谨的置信度度量工具，使其能够在非补偿性环境中有效识别高风险的分类边界，从而做出更为稳健的决策。

综上所述，本文的创新点如下：

1.我们将基于非常补偿性的多准则分类问题重构为一个概率化贝叶斯推断问题。建立贝叶斯流排序框架。将贝叶斯学习与流排序方法的非补偿性逻辑深度融合，设计了一种基于流值距离的似然函数。在此方法下，决策者的偏好参数（权重、阈值）被视为随机变量，通过融合先验知识与历史观测数据（已知分类）来推断其完整的后验分布。这不仅提供了分类置信度，更本质地捕捉并量化了偏好信息中内在的不确定性，为决策者提供了更丰富的决策信息。

2.针对于流排序方法依赖标准参考轮廓的问题，本文基于类内紧致性和类间分离度提出了两种在缺乏参考轮廓信息的情况下根据历史信息选择参考轮廓的方法，使得流排序方法的使用场景更加广泛，同时建立了缺乏参考轮廓情景下选择出参考轮廓后的贝叶斯模型，使得贝叶斯流排序的方法在缺乏标准参考轮廓下依然适用。

3.建立了与经典线性规划方法的系统性对比框架，验证了贝叶斯方法的高分类准确性，以及其软约束机制在复杂噪声环境下较好的鲁棒性。

本文的剩余部分组织如下。在第 2 节中，我们回顾了 FlowSort 方法。第 3 节介绍了一种新颖的贝叶斯流序模型。在第 4 节中，我们利用人工数据集实验来说明所提出的方法。第 5 节致力于与线性规划方法的对比实验研究。第 6 节总结了本文。

2.预备知识

本章简要回顾本文的方法论基础——流排序方法。作为一种基于流的非补偿性分类方法, FlowSort 结合了 PROMETHEE 的净流概念与参考轮廓的分类机制, 能够有效处理具有阈值限制的分类决策问题。

2.1 偏好结构与优势度量

FlowSort 的核心计算始于对备选方案之间偏好关系的刻画。对于任意两个评估对象 x, y（可以是备选方案或参考轮廓），其在准则 $g_j \in G$上的表现差异通过偏好函数$P_j(x, y) = F_j(d_j(x, y))$进行衡量，其中$d_j(x, y) = g_j(x) - g_j(y)$。在此基础上，通过归一化权重$w_j$聚合各准则信息，得到全局优势度$\pi(x, y)$：

$$\pi(x, y) = \sum_{j=1}^{n} w_j P_j(x, y) \tag{1}$$

其中$w_j > 0$ 且$\sum_{j=1}^{m} w_j = 1$。为了反映非补偿性特征, 通常采用带有漠视阈值q_j和偏好阈值p_j的分段线性函数。具体定义如下：

$$P_j(x, y) = F_j(d_j(x, y)) = \begin{cases} 0, & d_j(x, y) \le q \\ \dfrac{d_j(x, y) - q}{p - q}, & q < d_j(x, y) \le p \\ 1, & d_j(x, y) > p \end{cases} \tag{2}$$

该指标$\pi(x, y) \in [0,1]$定量描述了在考虑所有准则权衡后，对象x优于对象y的可信程度。

2.2 基于参考轮廓的流计算

为了实现分类，FlowSort 引入一组预定义的参考轮廓集$R = \{r_0, r_1, \ldots, r_k\}$

来界定k个有序类别$CL = \{CL_1, ..., CL_k\}$，其中r_0和r_k分别为最高和最低边界轮廓。

对于待分类方案$a_i \in A$，将其插入参考轮廓集构成扩展集合$R_i = R \cup \{a_i\}$。在该集合内，方案a_i的正向流$\phi^+(a_i)$、负向流$\phi^-(a_i)$及净流$\phi(a_i)$定义如下：

$$\phi^+(x_i) = \frac{1}{|R_i| - 1} \sum_{r_h \in R_i} \pi(x_i, r_h) \tag{3}$$

$$\phi^-(x_i) = \frac{1}{|R_i| - 1} \sum_{r_h \in R_i} \pi(r_h, x_i) \tag{4}$$

$$\phi(x_i) = \phi^+(x_i) - \phi^-(x_i) \tag{5}$$

同时，为了确定方案在扩展集中的相对位置，必须重新计算扩展集R_i中每个参考轮廓r_h的流值。参考轮廓r_h在扩展集中的正向流、负向流及净流计算公式如下：

$$\phi^+_{R_i}(r_h) = \frac{1}{|R_i| - 1} \left[\sum_{\substack{r_l \in R_i \\ l \neq h}} \pi\left(r_h, r_l\right) + \pi\left(r_h, x_i\right) \right] \tag{6}$$

$$\phi^-_{R_i}(r_h) = \frac{1}{|R_i| - 1} \left[\sum_{\substack{r_l \in R_i \\ l \neq h}} \pi\left(r_l, r_h\right) + \pi\left(x_i, r_h\right) \right] \tag{7}$$

$$\phi_{R_i}(r_h) = \phi^+_{R_i}(r_h) - \phi^-_{R_i}(r_h) \tag{8}$$

2.3 分类规则

为了将备选方案分配到合适的类别中，FlowSort 方法将其正向流和负向流分别与参考轮廓的正向流和负向流进行比较，比较依据分别根据以下规则：

$$if\ \phi^{+}_{R_i}(r_{h-1}) \geq \phi^{+}(x_i) > \phi^{+}_{R_i}(r_h), then\ C_{\phi^{+}}(x_i) = C \tag{9}$$

$$if\ \phi^{-}_{R_i}(r_{h-1}) < \phi^{-}(x_i) \leq \phi^{-}_{R_i}(r_h), then\ C_{\phi^{-}}(x_i) = C \tag{10}$$

但是按照单一的正向流或负向流进行分类, 可能会导致两种方案分到不同的类，为了将分到的类别进行统一，所以一般采取净流的规则:

$$if\ \phi_{R_i}(r_{h-1}) \geq \phi(x_i) > \phi_{R_i}(r_h), then\ C_{\phi}(x_i) = C_h \tag{11}$$

通过上述机制, FlowSort 严格遵循非补偿性偏好逻辑确定方案a_i的类别归属。而当决策者无法提供具体参数时, 如何通过引入贝叶斯学习去习得参数是我们接下来要讨论的问题。

3.一种新的非补偿性多准则分类的贝叶斯方法

3.1 问题描述

我们考虑一个非补偿性的多准则分类问题，以故障模式与影响分析 (FMEA) 为例，涉及将故障模式集合（即备选方案集合）$A = \{a_1, ... a_i, ... a_n\}$分配到 k 个预定义且具有顺序的等级类别 $CL = \{CL_1, ..., CL_k\}$，其中CL_{s+1}优于CL_s（表示为$CL_{s+1} \succ CL_s$），$s = 1, ..., k-1$，各个类别通过参考轮廓集合$R = \{r_0, r_1 ... r_{k-1}, r_k\}$进行划分，其中$r_0$和$r_k$分别是最高和最低的参考轮廓，即$r_0 \succ r_1 \succ ... \succ r_{k-1} \succ r_k$，类别从 1 到 k 有序排列，集合 A 中的每个备选方案必须被分配到且仅分配到一个决策类别。此类分类决策建立在决策者（DM）事先提供的偏好信息基础上，这些信息涉及参考备选方案的一组有限分配示例 $Q = \{q_1, ... q_l, ... q_x\}$，表示将备选方案 a_i 分配到某个类别中，作为已知的偏好信息。所有备选方案a_i通过准则集合（如严重度、发生概率、可探测度等）$G = \{g_1, ... g_j, ... g_m\}$进行评估，每个准则 g_j 是定量的，我们假设备选方案在单个准则上数值越高表现越好（必要时可通过转换满足这一假设）。

在经典的 FlowSort 模型中，分类决策过程是确定性的，即给定一组模型参数$\theta = \{w, p, q\}$以及界定类别的参考轮廓集$R = \{r_0, ..., r_k\}$，任意方案a_i均会被唯一地映射到某个类别CL_h中。然而，在实际决策支持场景中，要求决策者直接精确设定参数θ和参考轮廓R往往面临较高的认知负荷。通常情况下，决策者更容易提供的是一组包含有限个案的赋值示例，记为$Q = \{(a_l, \hat{c}_l) | l = 1, ..., x\}$，其中$\hat{c}_l \in CL$表示决策者将参考方案$a_l$指派到的真实类别。

基于此，本文的核心任务转化为一个参数学习问题，即如何仅依据部分且可能存在不一致性的偏好信息Q，推断出潜在的参数组合θ以及参考轮廓结构。不同于线性规划方法试图寻找单一的最优参数解，本文考虑到非补偿性模型参数空间的不适定性，即可能存在多组参数均能解释Q，将参数θ视为随机变量，目标是构建一个概率框架，结合先验知识与观测数据Q，推导参数的后验分布$P(\theta|Q)$，

从而在实现稳健参数学习的同时，为备选方案的分类结果提供具有统计意义的置信度量化。

3.2 偏好参数学习模型

在本节中，我们将描述所提出的贝叶斯流序模型方法。具体来说，我们应用贝叶斯规则，从决策者(DM)提供的偏好信息 Q 中推断价值函数模型参数的分布：

$$P(\theta|Q) = \frac{P(Q|\theta)P(\theta)}{P(Q)} = \frac{P(Q|\theta)P(\theta)}{\int P(Q|\theta)P(\theta)\,d\theta} \tag{12}$$

其中，$P(\theta)$和 $P(\theta|Q)$分别是价值函数模型参数的先验和后验分布（$\theta = \{\mathbf{w}, \mathbf{p}, \mathbf{q}\}$），$P(Q|\theta)$是给定价值函数模型参数的偏好信息的似然，$P(Q)$是归一化因子。为了构建似然 $P(Q|\theta)$，我们定义了通过价值函数模型生成每个备选方案分到某一类的概率，从而考虑了价值函数模型之间的概率差异。特别地，我们通过这种方式将概率质量分配给每个潜在的价值函数模型，不一定是兼容的，因此它提供了一个针对潜在有干扰的偏好信息的稳健解决方案。

所提出的贝叶斯方法的一个显著优势在于考虑了探索决策者偏好时的不确定性。这是因为该模型推导了潜在偏好模型的后验分布，而不是单一的偏好模型。另一个显著的优点在于其在设置潜在偏好模型的先验分布方面的灵活性。后者允许决策者表达偏好，例如，关于每个准则上边际价值函数的权衡权重。

3.2.1 先验分布

我们首先要讨论的是偏好参数的先验分布的设计，即漠视阈值 q_j 和偏好阈值 p_j，在每个准则 g_j（j=1,…,m）下是如何分布的。这些参数在 PROMETHEE 方法的分段线性偏好函数中起关键作用，分别表示决策者在两个备选方案评估值差距无差异的范围和完全偏好的界限。为了反映初始的无偏见假设，我们选择均匀分布作为 q_j 和 p_j 的先验分布。然而，考虑到这些参数的实际意义和约束条件，我们需要对其范围进行合理的限制。具体而言，假设每个准则 g_j 的评估值范围为 $[x_j^{min}, x_j^{max}]$，其中x_j^{min}和x_j^{max}分别表示该准则下所有备选方案的最小和最大评估值。为了保证模型的可解释性和实用性，我们设定 q_j 和 p_j 的取值范围必须满

足$0 < q_j < p_j < \Delta x$，其中Δx表示相邻参考轮廓或备选方案在准则 g_j 下的最小评估值差值。这一约束的引入基于以下考虑：如果 q_j 超过相邻评估值的差值，决策者将无法区分相邻类别之间的差异，导致分类边界模糊；同样，如果 p_j 过大，相邻参考轮廓之间的差异将不足以触发严格偏好，从而影响类别划分的精确性。

基于上述分析，qj 的先验分布可以定义为：

$$q_j = Uniform(0, \Delta x_j) \tag{13}$$

其中ϵ是一个极小正数（例如 10^{-6}），用于确保q_j不取零值，从而避免数值计算中的退化情况。同时，p_j 的先验分布需要满足$p_j > q_j$且$p_j < \Delta x_j$。为简化设计，我们假设在给定q_j的条件下，p_j 服从以q_j为下界的截断均匀分布：

$$p_j = Uniform(q_j + \varepsilon, \Delta x_j) \tag{14}$$

这种条件分布的设计确保了$p_j > q_j$的约束，同时保持了先验分布的均匀性，反映了初始状态下对p_j和q_j关系的无偏见假设。

接下来，我们设计准则权重的先验分布。权重 w_j（j=1,⋯,m）表示每个准则 g_j 相对于其他准则的重要性，满足 $w_j > 0$ 且$\sum_{j=1}^{m} w_j = 1$。由于初始状态下缺乏关于权重分布的先验信息，我们选择 Dirichlet 分布作为权重的先验分布，这是多变量正值随机变量的自然选择，能够保证权重和为 1 的约束条件。具体地，权重的先验分布定义为：

$$w_j(w_1, ..., w_m) = Dirichlet(\alpha_1, ..., \alpha_m) \tag{15}$$

其中$\boldsymbol{\alpha}_j$是 Dirichlet 分布的超参数，初始时假设无偏见，即$\boldsymbol{\alpha}_j = 1$（对应于均匀分布）。这种设定意味着每个准则的权重在初始状态下被认为具有相同的可能性，反映了决策者对各准则重要性的无先验偏好。Dirichlet 分布的概率密度函数为：

$$P(\boldsymbol{w}) = \frac{1}{B(\boldsymbol{\alpha})} \prod_{j=1}^{m} \boldsymbol{w}_i^{\alpha_j - 1} \tag{16}$$

其中 $B(\alpha)=\frac{\prod_{j=1}^{m}\tau(\alpha_j)}{\tau(\sum_{j=1}^{m}\alpha_j)}$是归一化常数，τ是 Gamma 函数。当$\alpha_j=1$ 时，密度函数简化为：

$$P(\boldsymbol{w})=\frac{1}{B(1,...1)}\prod_{j=1}^{m}\boldsymbol{w}_i^0=\frac{\tau(m)}{\tau(1)^m}=1 \tag{17}$$

这正是 m 维单位单纯形上的均匀分布，验证了我们的无偏见假设。同时，Dirichlet 分布的超参数α_j可以在燃烧期内根据已知偏好信息进行调整。

3.2.2 似然函数

为了应用贝叶斯规则来分析决策者的偏好，我们需要定义偏好信息的似然函数 $P(Q|\theta)$和价值函数模型的先验分布 $P(\theta)$。为了指定似然函数 $P(Q|\theta)$，我们假设每个已知真实分类的备选方案是独立的，因此我们可以将似然函数 $P(Q|\theta)$ 定义如下：

$$P(Q|\theta)=\prod_{q\in Q}P(q:a_i\in C_h|\theta) \tag{18}$$

其中 $P(q:a_i\in C_h|\theta)$是通过价值函数模型生成的备选方案a_i属于C_h的概率。然后，在定义 $P(q:a_i\in C_h|\theta)$时，我们提出以下概率形式，将备选方案与类别之间的选择联系起来，这意味着备选方案在类别之间的偏好关系：

$$P(q:a_i\in C_h|\theta)=\frac{e^{-(|\varphi(a_i)-\varphi(r_{h-1})|+|\varphi(a_i)-\varphi(r_h)|)}}{\sum_{r_l\in R_i}e^{-(|\varphi(a_i)-\varphi(r_{l-1})|+|\varphi(a_i)-\varphi(r_l)|)}} \tag{19}$$

在第 2 节中有关流的计算的基础上，此定义通过取指数形式，采用 Softmax 的函数形式为每个备选方案流值与类别上下阈值的流值之间的差值的绝对值（即到每个类别的距离）构建一个分布。我们选择这种形式有以下原因：首先，它将决策者(DM)偏好将一个备选方案分配到某一类别的概率同备选方案与类别之间的差距构建了一种直观的联系。备选方案 a_i 与类别 C_h 上下界差距总和越小，决策者断言 a_i 分配到 C_h 的概率越大。其次，它提供了一个重要的优势，即使对于相对较大的数据集，也具有计算可行性。

通过定义生成每个备选方案分配到某一类别的概率，我们解释了价值函数模型之间的概率差异。具有更大可能性 P(Q|θ)的价值函数更可能产生正确的偏好信息。

3.2.3 后验分布——Metropolis-Hastings 采样

通过上文对先验和似然的介绍，我们可以得到价值函数模型的后验分布为：

$$
\begin{aligned}
P(\theta|Q) &= \frac{P(Q|\theta)P(\theta)}{P(Q)} \\
&= \frac{\prod_{d=1}^{z} \frac{e^{-(|\varphi(a_i^d)-\varphi(r_{h-1})|+|\varphi(a_i^d)-\varphi(r_h)|)}}{\sum_{r_l \in R_i} e^{-(|\varphi(a_i^d)-\varphi(r_{l-1})|+|\varphi(a_i^d)-\varphi(r_l)|)}} P(\boldsymbol{w})\bullet P(\boldsymbol{p})\bullet P(\boldsymbol{q})}{P(Q)} \\
&= \frac{\prod_{d=1}^{z} \frac{e^{-(|\varphi(a_i^d)-\varphi(r_{h-1})|+|\varphi(a_i^d)-\varphi(r_h)|)}}{\sum_{r_l \in R_i} e^{-(|\varphi(a_i^d)-\varphi(r_{l-1})|+|\varphi(a_i^d)-\varphi(r_l)|)}} P(\boldsymbol{w})\bullet P(\boldsymbol{p})\bullet P(\boldsymbol{q})}{\int \prod_{d=1}^{z} \frac{e^{-(|\varphi(a_i^d)-\varphi(r_{h-1})|+|\varphi(a_i^d)-\varphi(r_h)|)}}{\sum_{r_l \in R_i} e^{-(|\varphi(a_i^d)-\varphi(r_{l-1})|+|\varphi(a_i^d)-\varphi(r_l)|)}} P(\boldsymbol{w})\bullet P(\boldsymbol{p})\bullet P(\boldsymbol{q}) d\theta}
\end{aligned}
\tag{20}
$$

我们观察到贝叶斯流序模型的目标是推断价值函数模型参数的分布，而不是根据给定的偏好信息和指定的先验来推断单一的偏好模型。任何遵循上述后验分布的价值函数模型都是表征决策者偏好的潜在偏好模型。分配给每个价值函数模型的后验概率质量反映了其重建决策者偏好信息的表达能力。总的来说，它考虑了探索决策者偏好中的不确定性，这是贝叶斯流序模型的显著特征之一。另一方面，根据贝叶斯推断的哲学，偏好模型的后验分布是关于先验信息和偏好信息的似然性之间的折衷。特别地，随着偏好信息中真实分类数量的增加，似然项支配着先验，并且偏好模型的后验分布更加集中在决策者真实偏好模型附近。

鉴于上述贝叶斯模型，推断价值函数模型参数的计算阶段需要推导后验分布 P(θ|Q)。由于先验 P(θ)与似然 P(Q|θ)不共轭，因此归一化因子 P(Q) = $\int \prod_{d=1}^{z} \frac{e^{-(|\varphi(a_i^d)-\varphi(r_{h-1})|+|\varphi(a_i^d)-\varphi(r_h)|)}}{\sum_{r_l \in R_i, l \neq h} e^{-(|\varphi(a_i^d)-\varphi(r_{l-1})|+|\varphi(a_i^d)-\varphi(r_l)|)}} P(\mathbf{w}) \cdot P(\mathbf{p}) \cdot P(\mathbf{q}) d\theta$没有闭式解，因此后验分布

$P(\theta|Q)$无法获得解析解。为了解决这个问题，我们使用马尔可夫链蒙特卡罗（MCMC）方法。

MCMC（马尔可夫链蒙特卡洛）方法的核心思想在于：在参数空间内构造一条马尔可夫链，使其平稳分布恰好为目标密度（即后验分布 $P(\theta|Q)$）。通过在该马尔可夫链上进行随机游走，能够生成服从后验分布 $P(\theta|Q)$的样本。这些样本可进一步用于推导后验分布 $P(\theta|Q)$的相关统计特征。

Algorithm 1 The Metropolis-Hastings algorithm for the proposed Bayesian approach

Input:

V(a):characteristic vectors of reference alternatives;
Q:the real classification provided by DM;
$\boldsymbol{\delta}$:parameter vector $\boldsymbol{\alpha}, \boldsymbol{\mu}, \boldsymbol{\sigma}$ of prior distribution;
M:number of iterations before convergence;
N:number of samples;

Output:

1:randomly generate initial state of Markov chain $\boldsymbol{\theta}_0$;
2:t←0;
3:**while** t<M+N **do**:
4: set $\boldsymbol{\theta}_{old} = \boldsymbol{\theta}_t$;
5: sample $\boldsymbol{\theta}_{new}$;
6: compute acceptance probability

$$r(\boldsymbol{\theta}_{old}, \boldsymbol{\theta}_{new}) = \min\left(1, \frac{P(Q|\theta')P(\theta')P(\theta|\theta')}{P(Q|\theta)P(\theta)P(\theta'|\theta)}\right)$$

7: sample $\varepsilon \sim Uniform(0,1)$;
8: **if** $\varepsilon < r$,**then**
9: $\boldsymbol{\theta}_{t+1} \leftarrow \boldsymbol{\theta}_{new}$;
10: **else**
11: $\boldsymbol{\theta}_{t+1} \leftarrow \boldsymbol{\theta}_{old}$;
12: **end if**
13: t←t+1;
14:**end while**
15:**return** samples$\{\boldsymbol{\theta}_{M+1}, \ldots, \boldsymbol{\theta}_{M+N}\}$.

我们采用马尔可夫链蒙特卡洛（MCMC）方法家族中的 Metropolis-Hastings（MH）算法（Chib & Greenberg, 1995）实施上述采样流程。我们以权重参数举

例，在该算法的每一轮迭代中，以概率 $y(\mathbf{w}_{old}, \mathbf{w}_{new})$提议从当前状态$\mathbf{w}_{old}$转移至新状态$\mathbf{w}_{new}$，其中 $y(\mathbf{w}_{old}, \mathbf{w}_{new})$被称作提议分布。正如 Murphy（2012）所述，定义提议分布的方式丰富多样。针对当前研究的问题，我们采用一种新状态独立于旧状态的分布，即独立采样器，具体形式如下：

$$y(\boldsymbol{w}_{old}, \boldsymbol{w}_{new}) = Dir(\boldsymbol{w}_{new}|\boldsymbol{\alpha}) \tag{26}$$

$$q_j^{new} \sim TruncatedNormal\left(\mu_q, \sigma_q; a = 0, b = \Delta x_j\right) \tag{27}$$

$$p_j^{new} \sim TruncatedNormal\left(\mu_p, \sigma_p; a = q_j^{new}, b = \Delta x_j\right) \tag{28}$$

由于 p 和 q 在均匀分布中采样随机性太强，可能会有很多提议被拒绝（很容易出现 p<q 的情况），在满足 p>q，同时保证 p 和 q 在规定范围内的同时提高采样效率，我们采取截断正态分布作为提议分布，其中 a 和 b 分别为截断下界和上界，μ和σ分别为均值和标准差。

有了从旧状态迁移到新状态的提议后，我们根据以下概率决定是否接受该提议：

$$r(\boldsymbol{\theta}_{old}, \boldsymbol{\theta}_{new}) = min\left(1, \frac{P(Q|\theta')P(\theta')P(\theta|\theta')}{P(Q|\theta)P(\theta)P(\theta'|\theta)}\right) \tag{29}$$

其中 $P(Q|\theta')$和 $P(Q|\theta)$代表新参数和旧参数下数据的似然概率；$P(\theta')$和 $P(\theta)$代表参数的先验概率；$P(\theta|\theta')$和 $P(\theta'|\theta)$从当前参数到新参数（或反向）的提议分布概率密度。

Metropolis-Hastings 方法的整体流程总结如算法 1 所示。在马尔可夫链达到平稳分布之前，需要一定数量的迭代（用 M 表示），关于设置 M 的说明可以在(Murphy, 2012)中找到。当马尔可夫链达到平稳分布时，我们可以从后验分布 $P(\theta|Q)$中对于参数 w，p 和 q 分别获得 N 个向量的样本。

3.3 参考轮廓学习模型

在上文我们讨论的标准的流排序方法通常假设决策者能够预先给出一组确定的参考轮廓$R = \{r_0, r_1 ... r_{k-1}, r_k\}$，用于界定不同类别的边界或中心。然而，

在实际的决策环境中，决策者往往难以提供一组精确的参考轮廓，或者仅仅拥有一些历史的分类数据（即已知部分备选方案属于哪一类）。在这种参考轮廓缺失的场景下，如何从现有的历史分类数据中提取或构建出具有代表性的参考轮廓，是应用贝叶斯流排序框架需要解决的前置问题。

针对这一问题，我们尝试从数据驱动的角度出发，将历史数据集中已分类的备选方案视为潜在的参考对象。我们并不试图去构造一个全新的虚拟点，而是尝试在每一类已有的备选方案中，筛选出最能代表该类特征的方案作为参考轮廓。为了实现这一筛选过程，本节探讨了两种启发式的选择策略：一种基于类内紧致性，另一种基于类间分离度。

3.3.1 基于类内紧致性的轮廓选择模型

基于类内紧致性的轮廓选择这种策略通过考查备选方案与其所属类别中其他成员的相似程度来确定其代表性。直观上，如果一个方案与同类中大多数方案都非常相似，那么它位于该类别的中心位置的可能性较大，以此作为参考轮廓能较好地反映该类别的整体特征。

设 A_h 为历史数据中被分到类别 C_h 的备选方案集合。对于该集合中的任意两个方案 $a_i, a_j \in A_h$，我们利用高斯核函数的思想定义它们之间的相似性 $s(a_i, a_j)$。为了消除不同准则量纲的影响，引入标准差 σ_t 对准则差值进行归一化处理：

$$s(a_i, a_j) = exp(-\frac{1}{m}\sum_{t=1}^{m}\frac{|g_t(a_i) - g_t(a_j)|}{\sigma_t}) \tag{21}$$

其中，m 为准则的总数，$g_t(a_i)$ 表示方案在第 t 个准则上的评价值，σ_t 为该准则下所有备选方案评分的标准差。

基于上述相似性定义，对于类别 C_h 中的每一个候选代表 $r \in A_h$，我们定义其综合相似度为该方案与类内其他所有方案相似性的均值：

$$\xi(r) = \frac{1}{|A_h| - 1}\sum_{a \in A_h, a \neq r} s(a, r) \tag{22}$$

其中，A_h 为 C_h 类中已知真实分类的方案数量。

在计算出所有候选方案的相似度后，我们选取均值最大的方案作为相应类别

的参考轮廓。这种方法倾向于选择那些位于类别分布密集的区域、能够最大程度代表类内共性的方案。

3.3.2 基于类间分离度的轮廓选择模型

基于类间分离度的轮廓选择这种策略则关注方案在类别边界上的区分能力。在多准则分类问题中，一个理想的参考轮廓应当不仅属于当前类别，还应与相邻类别的方案保持足够的距离，从而减少分类的模糊性。

为此，我们定义一个区分度函数$\delta(r, a)$，用于衡量当前类别的候选代表 r 与其他方案 a 之间的差异：

$$\delta(r, a) = \frac{1}{m}\sum_{t=1}^{m}\frac{|g_t(r) - g_t(a)|}{\sigma_t} \tag{23}$$

对于候选代表 $r \in A_h$，我们需要考察其与相邻类别中样本的区分程度。定义 r 的综合区分度 $d(r)$为其到相邻类别所有样本的平均距离：定义其与相邻类别的区分度：

$$d(r) = \frac{1}{|A_{h-1}| + |A_{h+1}|}\left(\sum_{a\in A_{h-1}}\delta(r, a) + \sum_{a\in A_{h+1}}\delta(r, a)\right) \tag{24}$$

需要说明的是，对于处于首尾的类别，上述公式中仅需计算其与唯一相邻类别的距离。最终，我们选择 $d(r)$最大的方案作为参考轮廓。与相似性策略不同，区分度策略更倾向于寻找那些特征鲜明、不易与相邻等级混淆的方案，这在强调类别辨识度的场景下可能更为有效。

3.3.3 无参考轮廓场景下的似然函数

在通过上述任一策略从历史数据中确定了参考轮廓集后，原本贝叶斯框架中的似然函数需要适配这种从数据中学习到的轮廓。结合前文构建的概率模型，在给定参数θ的条件下，历史数据中某个方案被正确划分到类别的似然概率可表示为：

$$P(q: a_i \in C_h|\theta) = \frac{e^{-(|\varphi(a_i)-\varphi(r_h)|)}}{\sum_{r_l \in R_i} e^{-(|\varphi(a_i)-\varphi(r_l)|)}} \tag{25}$$

其中，φ(·)代表基于当前参数下计算得到的净流。该似然函数同样采用了 softmax 的形式，其物理含义在于：如果一组参数能够使得备选方案的净流与它所属类别的参考轮廓的净流距离最近，而与其他类别的参考轮廓距离较远，则该组参数的似然值就越高。这一形式建立在选定的参考轮廓能够有效代表各类别特征的假设之上，从而实现了在无参考轮廓场景下的参数推断。

4.仿真实验与分析

为了验证所提出的贝叶斯流排序（BFS）方法的有效性，我们利用人工数据集进行了一系列仿真实验。实验设计旨在展示 BFS 框架如何利用部分偏好信息，推断 FlowSort 模型参数（准则权重、漠视阈值和偏好阈值），并最终实现准确分类。

4.1 实验设计

在本节中，我们展示了通过大量计算实验得出的结果，这些实验评估了 n 个备选方案在具有 m 个准则的人工数据集上 BFS 方法分类的表现。下面我们以其中的一次实验为例进行说明。

首先定义了一组分类轮廓，如下表所示。

类别	准则 1	准则 2	准则 3	准则 4
C1 边界	90	100	100	95
C2 边界	70	80	85	75
C3 边界	50	60	65	55
C4 边界	30	40	45	35
C5 边界	10	20	25	15
下限	0	0	5	5

表 1 分类轮廓

然后根据参考轮廓为 20 个备选方案随机生成每个准则的分数。然后我们利用计算机模拟决策者的偏好，为每个准则赋予偏好阈值和漠视阈值。然后我们使用 Flowsort 方法计算这 20 个备选方案根据模拟决策者偏好的准确分类。然后选取一定数量作为已知信息进行下一步贝叶斯学习。经过多轮实验，我们发现选取总数据量的 10%～20%作为已知信息，可以保证结果的准确率在 85%左右，甚至更高。在此次实验中，我们选取其中三个已知真实分类的备选方案构建我们贝叶斯公式的似然项。

为简化实验，我们假设未知先验信息，权重和偏好参数根据设定分别取狄利

克雷分布和均匀分布，根据学习的效果在后续迭代中更新分布的参数，由于均匀分布采样效率比较低，我们定义偏好参数 p 和 q 的提议分布为截断正态分布，其中 q 为区间$(0, \Delta x_j)$的截断正态分布，p 为区间$(q_j + \varepsilon, \Delta x_j)$的截断正态分布，同时由于未知任何偏好信息，我们最开始将 p 和 q 分布的区间三等分，取$\mu_q = 1/3U_j$，$\mu_p = 2/3U_j$，同时为避免无效采样（因为在区间外则会被拒绝，视为无效采样），尽可能使得采样值都在区间内，根据 3σ 法则，取$\sigma_q = 2/9U_j$，$\sigma_p = 2/9U_j$，这样可以保证区间内的值全部遍历的同时提高采样效率。

4.2 有参考轮廓实验结果分析

实验开始之前，我们取 $M = 1000$，确保燃烧期迭代充分(Murphy, 2012)，取 $N = 10000$ 进行最终分类结果的统计。

在完成上述参数设置后，我们采用算法 1 中的抽样程序从价值函数的后验分布中采集样本。经过 11000 次随机游走重复实验后，共获得 11000 组样本，每组样本对应一个特定的价值函数。当马尔可夫链经过 M=1000 次迭代后，可认为其已达到平稳分布。因此前 1000 个 u 样本被舍弃，剩余的 10000 个样本用于近似价值函数的后验分布。图 2 展示了各参数的轨迹图。为验证马尔可夫链在 1000 次随机游走后是否收敛，我们构建了三条起始状态不同的马尔可夫链，在图 3 中用不同颜色表示。观察发现每条马尔可夫链的轨迹图均无明显趋势。此外，对于参数的每个分量，三条马尔可夫链产生的轨迹图相互混合。这一现象表明上述三条马尔可夫链均已收敛至各自的平稳分布，因为它们已通过遍历性消除了初始状态的影响（Murphy, 2012）。此外，我们认为蒙特卡洛采样的接受率在 30%～70%之间最佳，过低表示采样效率太低，过高则可能探索空间不足，如图 2 所示，我们每迭代 500 次统计一次接受率，最终的接受率维持在 35%～40%之间，说明采样是有效的。

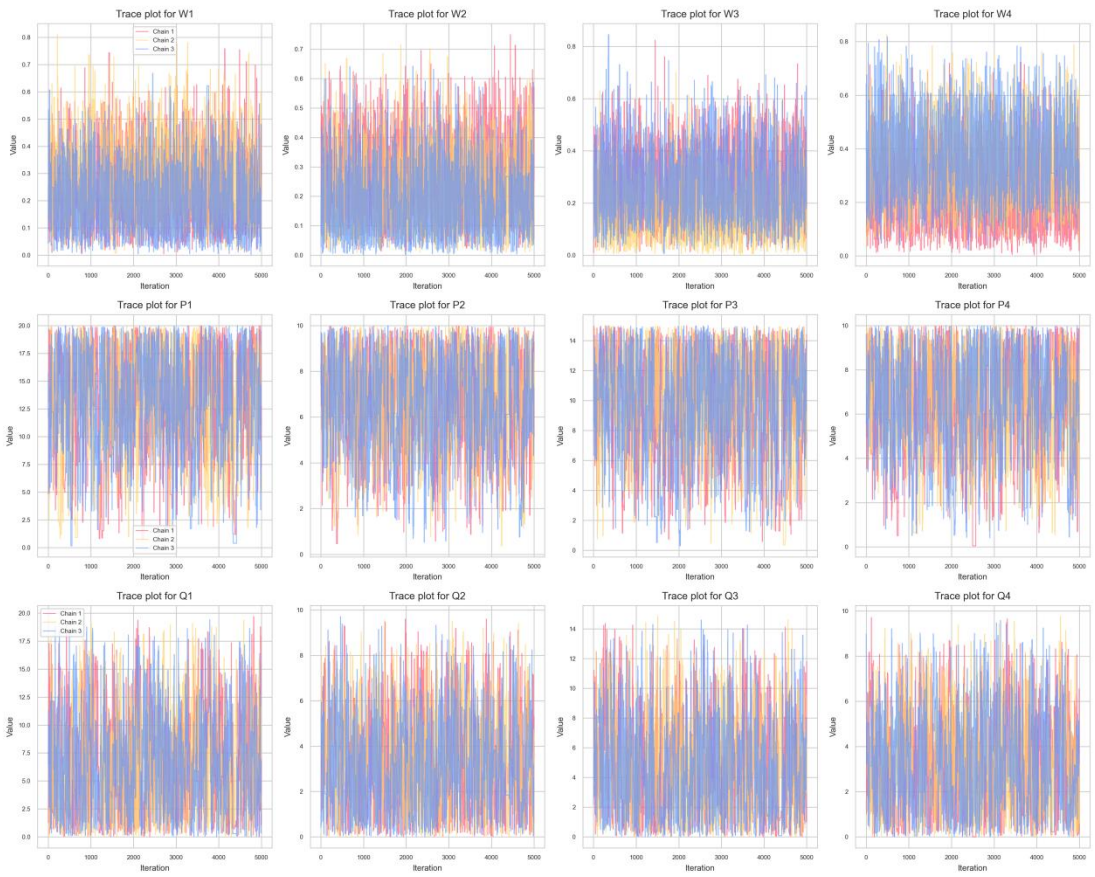

图 2 模型中参数的轨迹图

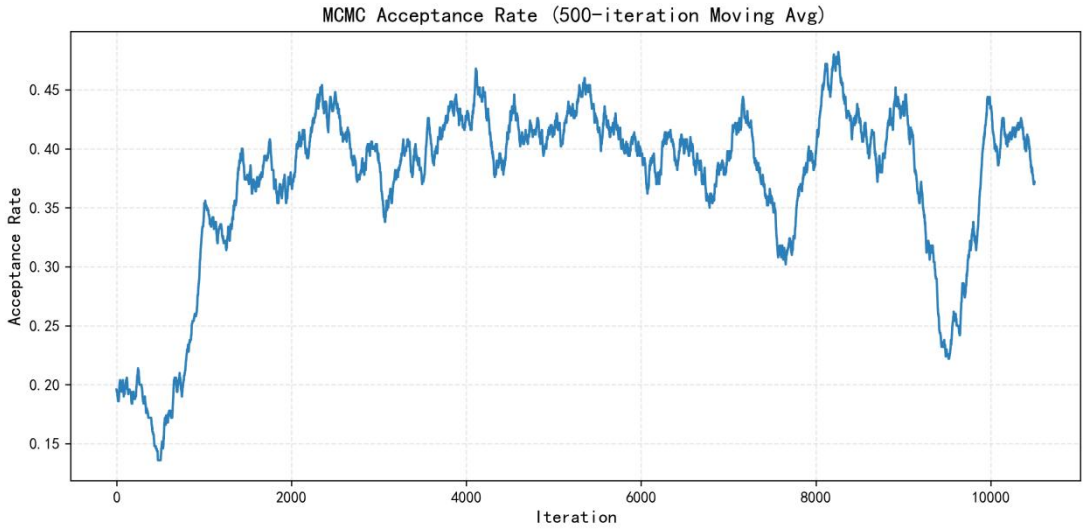

图 3 采样接受率

通过 BFS 方法得到所有备选方案的分类，表 2 展示了我们方法的学习成果。

ID	True Class	Class1 Prob	Class2 Prob	Class3 Prob	Class4 Prob	Class5 Prob

1	2	0.00%	100.00%	0.00%	0.00%	0.00%
2	5	0.00%	0.00%	0.00%	5.90%	94.10%
3	2	22.44%	77.56%	0.00%	0.00%	0.00%
4	5	0.00%	0.00%	0.00%	2.58%	97.42%
5	4	0.00%	0.00%	0.00%	76.21%	23.79%
6	2	99.60%	0.40%	0.00%	0.00%	0.00%
7	4	0.00%	0.00%	0.00%	100.00%	0.00%
8	2	0.00%	100.00%	0.00%	0.00%	0.00%
9	3	0.00%	0.00%	100.00%	0.00%	0.00%
10	5	0.00%	0.00%	0.00%	0.28%	99.72%
11	4	0.00%	0.00%	0.04%	99.96%	0.00%
12	3	0.00%	0.00%	72.53%	27.47%	0.00%
13	4	0.00%	0.00%	0.53%	99.47%	0.00%
14	2	0.00%	100.00%	0.00%	0.00%	0.00%
15	5	0.00%	0.00%	0.00%	34.33%	65.67%
16	4	0.00%	0.00%	2.85%	97.15%	0.00%
17	5	0.00%	0.00%	0.00%	1.06%	98.94%
18	3	0.00%	0.00%	100.00%	0.00%	0.00%
19	2	0.00%	98.97%	1.03%	0.00%	0.00%
20	2	35.73%	64.27%	0.00%	0.00%	0.00%

表 2 分类结果

实验结果验证了模型的有效性，表中结果显示，其中大部分方案都以较高的置信度分到了准确的类别，只有方案 6 分类错误（应当属于 2 类，却以 99.60% 的概率分到了 1 类），这可能是由于其准则下的评分靠近 1 类和 2 类轮廓的分界线导致的。同时我们可以获得一个分类的可信度，比如方案 1 我们有很大的把握分到第二类，对于方案 3，我们有较高的信心分到第二类，而对于方案 20，我们将其分到第二类的信心又将有所下降。

4.3 轮廓缺失场景下实验结果分析

在本节中，我们基于以上实验设计，在未知参考轮廓的场景下进行了两种轮廓学习方法的对比。需要注意的是，由于我们需要学习参考轮廓，所以我们需要知道其分到每个类别的一部分真实备选方案并获取其特征分布信息，所以为了保证学习到轮廓以及和以上有轮廓的实验进行对比，我们在原有实验的基础上进行以下设置：首先我们依旧选择 20 个备选方案进行实验，由于备选方案较少，此次实验我们先将所有的备选方案作为训练集输入模型以习得参考轮廓，然后再利用习得的轮廓重复有轮廓实验的流程，最后进行准确率对比分析。如图 4-5 所示，我们发现，利用我们自己习得的参考轮廓进行分类的准确率虽然较标准参考轮廓有所下降，但依然维持在一个比较高的水平。

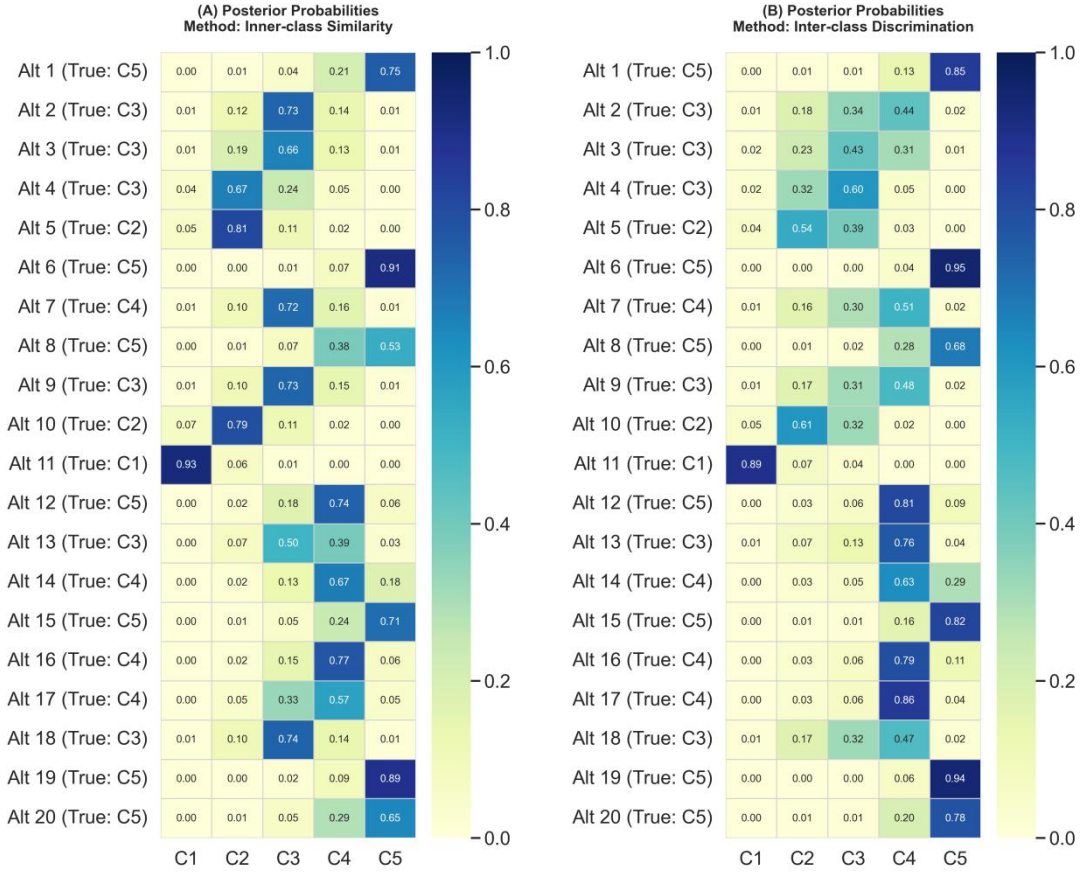

图 4-5 基于类内紧致性和类间分离度的分类准确率

由于现实场景中我们不可能已知全部的真实分类，所以我们进行轮廓学习的时候只能依赖部分已知数据，所以接下来我们将备选方案扩张到 100 个，并在

100 个数据集下进行实验，观察在每次实验给到每个类别已知真实分类数据不同的情况下的分类准确率。我们可以发现，基于类内紧致性的准确率略高一些，基本可以维持在 70% ~ 80%，这说明我们学习的效果还是较好的。

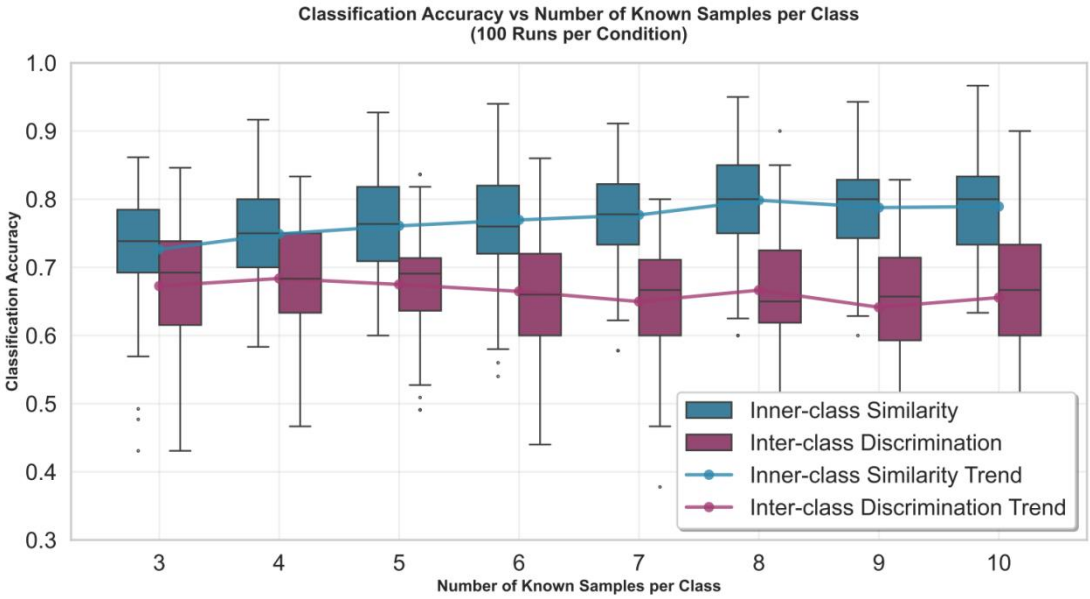

图 6 已知信息不同情况下的方法对比

本节针对无预设参考轮廓的非补偿性分类问题，设计了仿真实验以验证贝叶斯流排序框架的参数学习能力与分类性能。我们发现，模型能够在缺乏标准参照轮廓的情况下最终的分类准确率依旧可观，从而验证了此决策逻辑的可行性。

4.4 参数敏感性分析

在贝叶斯推断框架中，先验分布反映了对参数初始状态的假设。在前述实验中，我们对准则权重采用了无信息的狄利克雷先验分布，设定超参数α为 1。为了验证模型推断结果在面对不同初始信念时的稳健性，即验证模型推断结果是由数据驱动而非被先验主导，本节针对α进行了敏感性分析。我们构建了三种代表不同决策偏好强度的先验场景。第一种是稀疏先验，α设为 0.1，模拟决策者倾向于极端的权重分配，认为少数准则起决定性作用；第二种是均匀先验，α设为 1.0，即基准实验设定，代表无偏见的初始状态；第三种是集中先验，α设为 10.0，模拟决策者倾向于平均主义，认为各项准则的重要性差异不大。

多准则分类问题的核心目标在于分类结果的准确性与一致性。因此，我们分析了上述参数差异是否导致了决策结果的剧烈波动。图 7 展示了在三种先验场景下，所有备选方案分类结果的一致性热力图。图中每一行代表一个备选方案在不同先验下的分类归属，横轴代表不同的先验设定，颜色的一致性直观地反映了决策的稳定性。

图 7 不同参数下的分类结果

统计分析表明，分类决策表现出了较高的稳健性。绝大多数的备选方案在三种截然不同的先验假设下被划分到了相同的类别中，仅有极少数位于类别边界附近的模糊样本发生了分类跳变。这一结果有力地证明了 BFS 框架具有决策级稳健性，模型能够输出稳定且可信的分类建议。这表明本研究采用无信息先验是合理且可靠的，其决策建议主要由历史数据驱动，而非受限于先验参数的人为设定。

5.方法对比分析

为了更好地验证方法的有效性, 我们将在此章节通过与线性规划方法进行对比来验证贝叶斯流排序方法在已知信息量较少以及存在潜在错误偏好信息这两种情况下表现出的优势。本章安排如下，首先我们先基于非补偿性问题利用线性规划的思想建模，然后进行对比实验，为简单起见，我们沿用前面的数据集继续后续的讨论。

5.1 线性规划方法建模

为进行充分的说明, 我们分别从最小化分类错误以及最大化分类间隔两个角度出发进行线性规划方法的建模。其中最小分类错误的方法将已知偏好信息作为严格约束进行求解, 而最大分类间隔方法目的是通过将间隔放大来满足分类约束, 同时容忍一定的分类误差，较最小分类错误方法有一定的鲁棒性。首先是最小化分类错误(MinError):

$$min \sum_{k=1}^{K} \epsilon_k \tag{30}$$

其中 K 是已知样本数量，ϵ_k是第 k 个样本的松弛变量。其参数范围约束:

$$\begin{cases} q_j \le p_j \le U_j \quad j = 1, \dots, m \\ q_j \ge 0 \quad j = 1, \dots, m \\ w_j > 0, \sum_{j=1}^{m} w_j = 1 \end{cases}$$

参考点排序约束:

$$\phi(r_h) \ge \phi(r_{h+1}) \qquad h = 1, \dots, n-1$$

其中 $\phi(r_h)$是参考点r_h的净流值，对于每个已知样本$x_k \in C_{t_k}$:

$$\begin{cases} \phi(x_k) \ge \phi(r_{t_k}) - \epsilon_k \quad if \quad t_k \ne 1 \\ \phi(x_k) \le \phi(r_{t_k - 1}) + \epsilon_k \quad if \quad t_k \ne T \end{cases}$$

其中 T 是类别总数，$\phi(r_{t_k})$是类别t_k的下界净流值。

接下来是最大分类间隔方法 (MaxMarginFlowSort)：

$$max\ \gamma - \lambda \sum_{k=1}^{K} \xi_k \tag{31}$$

γ为与类别边界的距离，满足$\gamma \geq 0$，ξ_k是松弛变量，满足$\xi_k \geq 0$，其参数范围约束以及参考点排序约束同上方最小分类错误方法，同理，对于每个已知样本$x_k \in C_{t_k}$：

$$\begin{cases} \phi(x_k) \geq \phi(r_{t_k}) + \gamma - \xi_k & if\ \ t_k \neq 1 \\ \phi(x_k) \leq \phi(r_{t_k-1}) - \gamma + \xi_k & if\ \ t_k \neq T \end{cases}$$

其中 T 是类别总数，$\phi(r_{t_k})$是类别t_k的下界净流值。

5.2 对比实验

为公平起见，我们同样为最小分类错误以及最大分类间隔两种方法随机选取和贝叶斯流排序方法一样的三个方案作为约束条件，我们依旧以 4 个准则，20 个备选方案为例，在通过以上规则生成的 100 个人工数据集下对比三种方法。本节我们将具体分析实验的结果。

在分类结果上，线性规划的方法分出来的结果是确定性的，即要么分到这个类别，要么不分到这个类别，贝叶斯流排序方法得到的分类结果具有置信度的衡量，即有多大把握分到这个类别。如图 8 所示，在其中的一次实验中，线性规划的两种方法要么显示为 1，要么显示为 0，贝叶斯则是在 0 ~ 1 之间进行取值。这样的优势在于，我们得到分类结果以后，可以知道我们将某个备选方案分到某一类的信心，同时，比如我们看备选方案 9 以及备选方案 13，线性规划的方法可能会出现类似于这样的问题，即如果分类错误，那将完全否定正确的类别，而贝叶斯仍然有一定的信心将其分到正确的类。

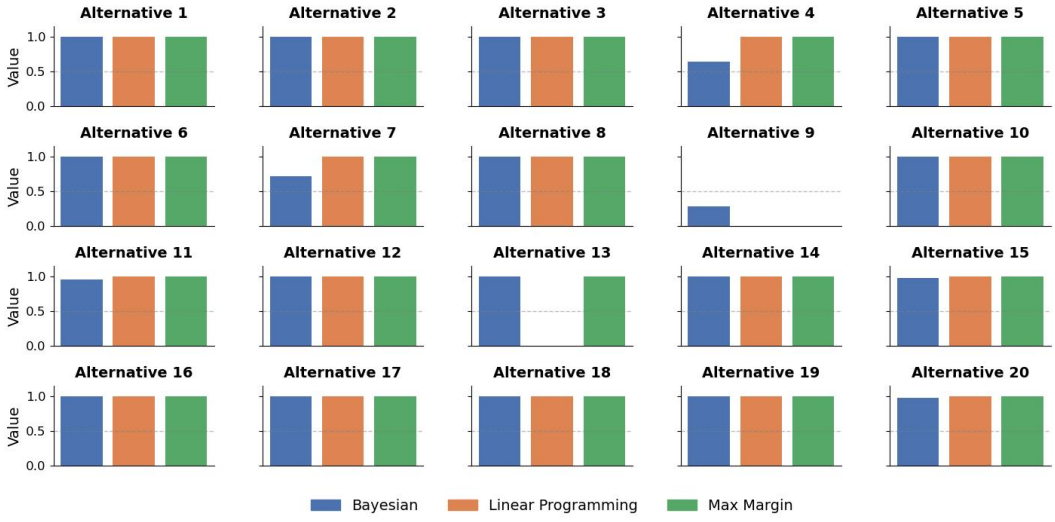

图 8 实验分类准确率对比

图 9-11 展示了 100 个数据集实验结果的混淆矩阵，横轴表示预测类别，纵轴表示真实类别，也就是说，在对角线上的备选方案数量越多，分类的结果越准确。同时要注意的是，贝叶斯方法无法得到一个唯一的分类结果，为了衡量准确性，我们设定了一个小规则，我们认为在贝叶斯流排序的方法中，如果某个备选方案在某一类的置信度大于等于 75%, 决策者最终做决策时应当将其分到这个类别。基于此，我们将大于等于 75%设定为 1，当然你也可以认为大于一半的概率即可接受，这都取决于决策者的主观判断，并且这样的话，将可能继续增加贝叶斯方法预测的准确性。通过观察得到的三种方法的混淆矩阵，我们发现，100 个数据集下一共 2000 个备选方案，在贝叶斯流排序的分类下，只有 8 个方案分到了错误的类别，显著高于其他的方法，这体现了贝叶斯方法在已知偏好信息较少时的优势。

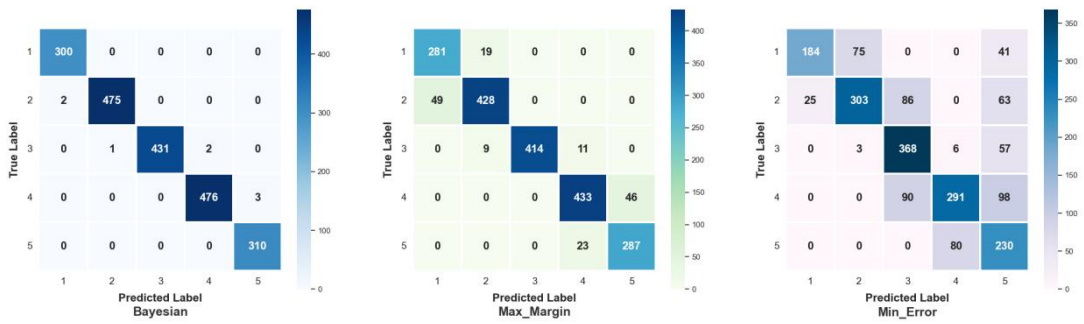

图 9-11 三种方法分类混淆矩阵

接着我们进行了鲁棒性的检验，我们将上面的实验进行了一定的调整，在选取的三个偏好信息中，我们将其中的一个改为错误的偏好信息，以检验三种方法在存在错误信息时分类准确率的变化情况。

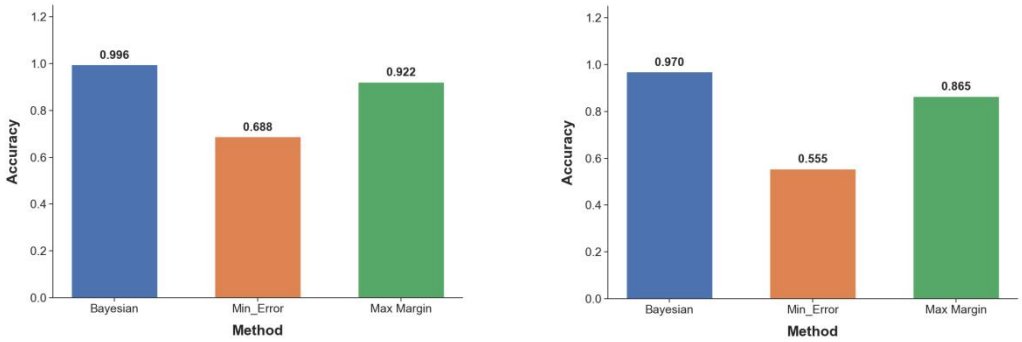

图 12-13 三种方法是否存在错误信息的准确率对比（后者为存在）

通过对比有无错误信息前后的准确率，我们发现，最小分类错误的方法由于其严格按照约束进行求解，所以准确率下降最多，由开始的 0.688 降为 0.555；最大分类间隔从 0.922 降为 0.865，下降幅度较小，这是因为其虽然按照约束进行求解，但方式不同，这个方法通过扩大分类间隔，从而使备选方案更容易落到真实类别中，同时还容忍一定的分类错误，具有一定的鲁棒性；最后再看贝叶斯流排序的方法，仅仅是从 0.996 降为 0.970，为什么加入错误信息之后对于贝叶斯方法几乎没有影响呢？这是由于我们设定的规则，即选取置信度大于等于 75% 的类别作为最终分类，当然这符合决策者在决策时的思考逻辑，一般都会选择最大可能的方案作为最后的结果。所以，即便会有一些方案受到错误信息的影响，从而导致真实分类的概率有所下降，但大多数还是分到正确类别的概率最大，使得决策者仍然可以做出准确的选择，这体现出了贝叶斯流排序方法优秀的鲁棒性能。

接着我们在相同的实验设置下，移除预设的参考轮廓信息，对比了三种方法的表现。对于线性规划方法，若直接将参考轮廓设定为待优化的决策变量，势必会在约束条件中引入权重与轮廓值的耦合项，这将使得原本的线性优化问题转化为复杂的非线性规划问题，不仅求解难度呈指数级上升，且极易因自由度过高而产生缺乏实际意义的退化解。因此，我们在实验中采用了与贝叶斯方法相同的策略，即先利用前文所述的方法从历史数据中学习出参考轮廓，并将其作为固定参数引入模型。此时，由于不再拥有确定的类别边界，线性规划的约束条件由传统

的上下界限转变为基于中心轮廓的相似性约束，即要求备选方案与所属类别的参考轮廓在流值上最为接近，从而实现分类。

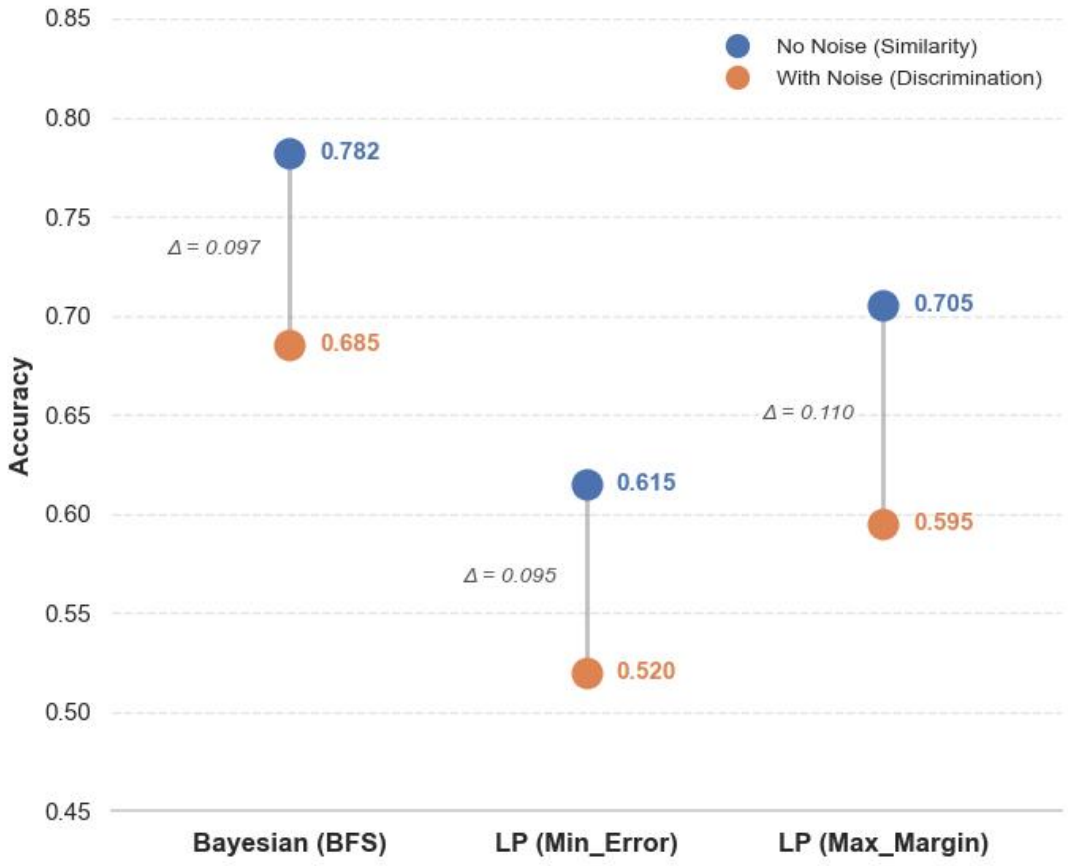

图 14 参考轮廓缺失场景下对比分析

图 14 展示了在轮廓缺失情况下三种方法的分类准确率对比。从图中结果可以看出，贝叶斯流排序方法在缺乏标准参考轮廓时依然保持了较高的分类水准，准确率明显优于两种线性规划方法。最小分类错误方法的性能下降最为显著。这是因为该方法在将学习到的参考轮廓作为绝对基准时，为了严格满“训练样本必须与所属类别的轮廓最近”这一硬性线性约束，往往会推断出过度拟合训练数据的权重和阈值组合。一旦学习到的轮廓本身存在偏差，这种刚性的约束机制就会导致模型在面对未知测试样本时，分类边界出现严重偏移。

相比之下，最大分类间隔方法虽然通过引入间隔最大化目标，试图在满足最近邻约束的同时扩大分类的容错空间，但在面对轮廓偏差时，其改善效果依然有限。贝叶斯流排序框架则展现出了本质的不同，它同样基于学习到的参考轮廓，但并非将其作为刚性的约束条件。相反，BFS 通过构建基于距离的似然函数，以概率化的方式容纳了备选方案与轮廓之间的偏差。这种软约束有效化解了轮廓估

计中的不确定性，使得模型即使在参考轮廓不完美的情况下，仍能基于数据分布构建出稳健的后验推断。

6.总结

本文针对非补偿性多准则分类问题中经典流排序（FlowSort）方法参数依赖性强、缺乏不确定性量化以及难以应对参考轮廓信息缺失场景等局限，提出了一种贝叶斯流排序（BFS）框架。该框架将参数推断转化为概率化建模过程，并通过 Metropolis-Hastings 算法进行后验采样。通过构建大量仿真实验，并与经典的线性规划方法进行对比，我们发现，贝叶斯推断在分类准确性与置信度量化上具有显著优势。

首先，仿真实验结果表明，BFS 框架在处理多准则分类任务时表现出较高的准确性。在基于 100 个数据集（共 2000 个测试样本）的实验中，在我们预设的规则下，即分类置信度达到 75%以上我们就认为该备选方案属于此类，BFS 方法仅出现 8 例误判，准确率显著优于线性规划的方法。更重要的是，与线性规划方法输出的确定性结果不同，BFS 能够基于后验概率为每个备选方案提供其属于特定类别的置信度衡量，为决策者提供了比单纯分类结果更丰富的风险评估依据。

其次，相较于线性规划方法，贝叶斯流排序方法在面对存在噪声的偏好信息时表现出更优秀的鲁棒性也在本文中得到了验证。在引入错误偏好信息的鲁棒性测试中，线性规划方法表现出明显的脆弱性，MinError 方法的分类准确率从 68.8%下降至 55.5%，表明其严格约束机制对噪声较为敏感；MaxMargin 方法虽有一定抗噪能力，但准确率也从 92.2%下降至 86.5%；而 BFS 方法展现出较强的鲁棒性，准确率仅从 99.6%微幅下降至 97.0%。 这一结果证实，通过将参数视为随机变量并构建软约束的似然函数，BFS 能够有效处理个别错误样本的干扰，在信息不完美的情况下依然保持决策的稳定性。

最后，在缺乏参考轮廓场景下，实验验证了本文提出的基于类内紧致性和类间分离度的轮廓学习策略的有效性。在参考轮廓缺失的对比实验中，BFS 结合

轮廓学习策略，其分类准确率显著优于线性规划方法。实验分析指出，线性规划方法在学习轮廓时容易陷入过拟合，导致面对未知样本时分类边界偏移；而 BFS 通过概率化的距离度量，有效化解了轮廓估计带来的不确定性，证明了该框架在信息匮乏场景下的适用潜力。

尽管本研究在非补偿性分类的概率化建模方面取得了一定进展，但仍存在若干局限有待后续探索。首先，当前采用的 Metropolis-Hastings 算法在处理高维决策空间或海量历史数据时面临计算开销大、混合时间长的问题，未来可引入变分推断或 NUTS 等高效采样策略以提升模型的实时响应能力；其次，现有的无信息先验假设未充分利用领域专家知识，后续研究应致力于设计更灵活的先验结构以融合数据驱动与知识驱动信息；此外，本研究仅聚焦于 FlowSort 模型，未来可进一步验证该贝叶斯框架在 ELECTRE-TRI 等其他非补偿性模型中的普适性，并将方法应用于动态供应链评级、环境风险实时监测等更具复杂性与不确定性的真实场景中，以全面检验其在异构数据环境下的有效性与稳定性。

参考文献

[1] Emamat M, Mota C, Mehregan M, et al. Using ELECTRE-TRI and FlowSort methods in a stock portfolio selection context [J]. Financial Innovation, 2022, 8(1).

[2] Alizadeh P, Amiri M. A decision support approach for financial policy measures selection [J]. Journal of Science and Technology Policy Management, 2024, 15(1): 53–66.

[3] Shi J, Sun M, Yang X, et al. Evaluating supply chain finance risks in a cross-border e-commerce context: An improved TOPSIS approach with loss penalty [J]. Inf Sci, 2025, 717.

[4] Hu H, Jiang S, Goswami S, et al. Fuzzy Integrated Delphi-ISM-MICMAC Hybrid Multi-Criteria Approach to Optimize the Artificial Intelligence (AI) Factors Influencing Cost Management in Civil Engineering [J]. Information, 2024, 15(5).

[5] Fu C, Xue M, Liu W, et al. Data-driven preference learning in multiple criteria decision making in the evidential reasoning context [J]. Appl Soft Comput, 2021, 102.

[6] Levy K, Chasalow K, Riley S. Algorithms and Decision-Making in the Public Sector [M]//HANS V P. Annual Review of Law and Social Science, Vol 17. 2021: 309–334.

[7] Belahcène K, Mousseau V, Ouerdane W, et al. A guided tour of multiple criteria sorting models and methods [J]. Ann Oper Res, 2024, 343(2): 785–845.

[8] Qi Z, Li H, Zhang K, et al. An attribute fuzzy concept-oriented three-way utility decision model in multi-attribute environments [J]. Appl Soft Comput, 2023, 143.

[9] Kumari B, Pandey A. Geo-informatics based multi-criteria decision analysis (MCDA) through analytic hierarchy process (AHP) for forest fire risk mapping in Palamau Tiger Reserve, Jharkhand state, India [J]. Journal of Earth System Science, 2020, 129(1).

[10] Islam M, Aziz M, Alauddin M, et al. Site suitability assessment for solar power plants in Bangladesh: A GIS-based analytical hierarchy process (AHP) and multi-criteria decision analysis (MCDA) approach [J]. Renew Energy, 2024, 220.

[11] Banihabib M, Chitsaz N, Randhir T. Non-compensatory decision model for incorporating the sustainable development criteria in flood risk management plans [J]. Sn Applied Sciences, 2020, 2(1).

[12] Nemery P, Lamboray C. FlowSort: a flow-based sorting method with limiting or central profiles [J]. Top, 2008, 16(1): 90–113.

[13] Lev B. Multiple criteria decision analysis: An integrated approach [J]. Interfaces, 2003, 33(2): 77–79.

[14] Sadabadi S, Hadi-Vencheh A, Jamshidi A, et al. A linear programming technique to solve fuzzy multiple criteria decision making problems with an application [J]. Rairo-Operations Research, 2021, 55(1): 83–97.

[15] Besbes O, Fonseca Y, Lobel I. Contextual Inverse Optimization: Offline and Online Learning [J]. Operations Research, 2025, 73(1).

[16] Shahmoradi Z, Lee T. Quantile Inverse Optimization: Improving Stability in Inverse Linear Programming [J]. Operations Research, 2022, 70(4).

[17] Ulucan A, Atici K. A MULTIPLE CRITERIA SORTING METHODOLOGY WITH MULTIPLE CLASSIFICATION CRITERIA AND AN APPLICATION TO COUNTRY RISK EVALUATION [J]. Technological and Economic Development of Economy, 2013, 19(1): 93–124.

[18] Douissa M, Jabeur K. A non-compensatory classification approach for multi-criteria ABC analysis [J]. Soft Computing, 2020, 24(13): 9525–9556.

[19] Scholten L, Schuwirth N, Reichert P, et al. Tackling uncertainty in multi-criteria decision analysis - An application to water supply infrastructure planning [J]. Eur J Oper Res, 2015, 242(1): 243–260.

[20] Fan Z, Zhang X, Chen F, et al. Multiple attribute decision making considering aspiration-levels: A method based on prospect theory [J]. Comput Ind Eng, 2013, 65(2): 341–350.

[21] Wieckowski J, Salabun W. Sensitivity analysis approaches in multi-criteria decision analysis: A systematic review [J]. Appl Soft Comput, 2023, 148.

[22] WIND Y, SAATY T. MARKETING APPLICATIONS OF THE ANALYTIC HIERARCHY PROCESS [J]. Management Science, 1980, 26(7): 641–658.

[23] KARAYALCIN I. THE ANALYTIC HIERARCHY PROCESS - PLANNING, PRIORITY SETTING, RESOURCE-ALLOCATION - SAATY,TL [J]. Eur J Oper Res, 1982, 9(1): 97–98.

[24] Vinogradova-Zinkevic I. Comparative Sensitivity Analysis of Some Fuzzy AHP

Methods [J]. Mathematics, 2023, 11(24).
[25] Jorge-Garcia D, Estruch-Guitart V. Comparative analysis between AHP and ANP in prioritization of ecosystem services-A case study in a rice field area raised in the Guadalquivir marshes (Spain) [J]. Ecological Informatics, 2022, 70.
[26] Chen Z, Zhang X, Rodríguez R, et al. Expertise-based bid evaluation for construction-contractor selection with generalized comparative linguistic ELECTRE III [J]. Autom Constr, 2021, 125.
[27] Opricovic S, Tzeng G. Compromise solution by MCDM methods: A comparative analysis of VIKOR and TOPSIS [J]. Eur J Oper Res, 2004, 156(2): 445–455.
[28] DENG J. CONTROL-PROBLEMS OF GREY SYSTEMS [J]. Systems & Control Letters, 1982, 1(5): 288–294.
[29] BRANS J, VINCKE P. A PREFERENCE RANKING ORGANIZATION METHOD - (THE PROMETHEE METHOD FOR MULTIPLE CRITERIA DECISION-MAKING) [J]. Management Science, 1985, 31(6): 647–656.
[30] Liao H, Xu Z. Multi-criteria decision making with intuitionistic fuzzy PROMETHEE [J]. Journal of Intelligent & Fuzzy Systems, 2014, 27(4): 1703–1717.
[31] Ince M, Tasdemir C. Facility Location Selection and Layout Planning through AHP, PROMETHEE, and CORELAP Methods in the Furniture Industry [J]. Bioresources, 2024, 19(3): 6478–6509.
[32] Mousseau V, Figueira J, Naux J. Using assignment examples to infer weights for ELECTRE TRI method: Some experimental results [J]. Eur J Oper Res, 2001, 130(2): 263–275.
[33] Remadi F, Frikha H. An extension of the FLOWSORT method based on intuitionistic fuzzy set theory to solve Multicriteria Decision Making problems [J]. Rairo-Operations Research, 2022, 56(3): 1491–1501.
[34] de Banos G, Pereira V, Roboredo M. ELECTRE tree: a machine learning approach to infer ELECTRE Tri-B parameters [J]. Data Technologies and Applications, 2021, 55(4): 586–608.
[35] Pelissari R, Oliveira M, Ben Amor S, et al. A new FlowSort-based method to deal with information imperfections in sorting decision-making problems [J]. Eur J Oper Res, 2019, 276(1): 235–246.
[36] Mousseau V, Slowinski R. Inferring an ELECTRE TRI model from assignment

examples [J]. Journal of Global Optimization, 1998, 12(2): 157–174.
[37] 王坚强. 几类信息不完全确定的多准则决策方法研究 [D]; 中南大学, 2005.
[38] Dias L, Clímaco J. ELECTRE TRI for groups with imprecise information on parameter values [J]. Group Decision and Negotiation, 2000, 9(5): 355–377.
[39] 秦成燕. 区间数的可信度定义及区间线性规划基 B 稳定问题的研究 [D]; 杭州电子科技大学, 2011.
[40] Figueira J, Greco S, Slowinski R. Building a set of additive value functions representing a reference preorder and intensities of preference: GRIP method [J]. Eur J Oper Res, 2009, 195(2): 460–486.
[41] Kadzinski M, Tervonen T. Robust multi-criteria ranking with additive value models and holistic pair-wise preference statements [J]. Eur J Oper Res, 2013, 228(1): 169–180.
[42] Hansknecht C, Kirches C, Manns P. Convergence of successive linear programming algorithms for noisy functions [J]. Computational Optimization and Applications, 2024, 88(2): 567–601.
[43] Ben-Tal A, Nemirovski A. Robust solutions of Linear Programming problems contaminated with uncertain data [J]. Mathematical Programming, 2000, 88(3): 411–424.
[44] Middleton J. Effect of analytical error on the assessment of cardiac risk by the high-sensitivity C-reactive protein and lipid screening model [J]. Clinical Chemistry, 2002, 48(11): 1955–1962.
[45] Wang C, Feng Z. A Flexible Method for Diagnostic Accuracy with Biomarker Measurement Error [J]. Mathematics, 2023, 11(3).
[46] Berringer H, Metcalfe R, Harari O, et al. BENEFIT-RISK ASSESSMENT OF MEDICAL PRODUCTS USING BAYESIAN MULTI-CRITERIA AUGMENTED DECISION ANALYSIS (MCADA) [J]. Value in Health, 2024, 27(6): S248–S249.
[47] Berringer H, Metcalfe R, Vuong Q, et al. REAL-LIFE BENEFIT-RISK ASSESSMENT OF MEDICAL PRODUCTS USING BAYESIAN MULTI-CRITERIA AUGMENTED DECISION ANALYSIS (MCADA) IN ONCOLOGY [J]. Value in Health, 2024, 27(12).
[48] Ru Z, Liu J, Kadzinski M, et al. Bayesian ordinal regression for multiple criteria choice and ranking [J]. Eur J Oper Res, 2022, 299(2): 600–620.
[49] Yu R, Abdel-Aty M. Investigating different approaches to develop informative

priors in hierarchical Bayesian safety performance functions [J]. Accident Analysis and Prevention, 2013, 56: 51–58.

[50] Bois F, Brochot C. A Bayesian framework for virtual comparative trials and bioequivalence assessments [J]. Frontiers in Pharmacology, 2024, 15.

[51] Kavelaars X, Mulder J, Kaptein M. Bayesian Multivariate Logistic Regression for Superiority and Inferiority Decision-Making under Observable Treatment Heterogeneity [J]. Multivariate Behavioral Research, 2024, 59(4): 859–882.

[52] Burda M, Harding M, Hausman J. A Bayesian mixed logit-probit model for multinomial choice [J]. Journal of Econometrics, 2008, 147(2): 232–246.

[53] Lye A, Marino L, Cicirello A, et al. Sequential Ensemble Monte Carlo Sampler for On-Line Bayesian Inference of Time-Varying Parameter in Engineering Applications [J]. Asce-Asme Journal of Risk and Uncertainty in Engineering Systems Part B-Mechanical Engineering, 2023, 9(3).

[54] Hüllermeier E, Slowinski R. Preference learning and multiple criteria decision aiding: differences, commonalities, and synergies-part II [J]. 4or-a Quarterly Journal of Operations Research, 2024, 22(3): 313–349.

[55] Hüllermeier E, Slowinski R. Preference learning and multiple criteria decision aiding: differences, commonalities, and synergies-part I [J]. 4or-a Quarterly Journal of Operations Research, 2024.

[56] Ru Z, Liu J, Kadzinski M, et al. Probabilistic ordinal regression methods for multiple criteria sorting admitting certain and uncertain preferences [J]. Eur J Oper Res, 2023, 311(2): 596–616.

[57] Kavianihamedani H, Quinn J, Smith J. New Diagnostic Assessment of MCMC Algorithm Effectiveness, Efficiency, Reliability, and Controllability [J]. IEEE Access, 2024, 12: 42385–42400.